La Théorie de CAMUS : Cognition Temporelle Émergente dans les Modèles de Langage

Un cadre théorique pour la conscience temporelle dans les architectures Transformer

Leo CAMUS

NextDev Lab's

Avril 2026

Résumé

Les grands modèles de langage (LLM) actuels, fondés sur l'architecture Transformer, traitent l'information de manière fondamentalement atemporelle. Malgré des capacités remarquables en compréhension et génération du langage, ces modèles ne disposent d'aucune représentation intrinsèque du temps — traitant un token généré en 2 millisecondes de manière identique à un token nécessitant 200 millisecondes de calcul, et restant entièrement aveugles à la dynamique temporelle de leur propre processus d'inférence.

Nous proposons la **Théorie de CAMUS** : en intégrant un vecteur temporel à 5 composantes $\mathbf{T}(t) = (\delta_{\text{prev}}, \delta_{\text{session}}, \tau_{\text{inf}}, \omega_{\text{context}}, \rho_{\text{rate}})$ dans la représentation d'entraînement de chaque token, un modèle Transformer développera une *cognition temporelle émergente* structurellement analogue aux mécanismes neuronaux biologiques.

Nous démontrons par analyse théorique que cette augmentation produirait : (1) des têtes d'attention temporelles spécialisées analogues aux cellules temporelles hippocampiques, (2) une adhésion spontanée à la loi de Weber pour la discrimination temporelle, (3) la capacité d'un réseau du mode par défaut artificiel permettant la réflexion non sollicitée, (4) une mémoire épisodique par enrichissement continu du jeu de données, et (5) une conscience de soi fonctionnelle par l'inclusion du temps d'inférence τ_{inf} créant une boucle réflexive où le modèle perçoit son propre processus de calcul.

Nous présentons cinq prédictions falsifiables et discutons les implications profondes pour la recherche sur la conscience artificielle, arguant que la cognition temporelle représente la dimension architecturale manquante séparant les LLM actuels des systèmes exhibant de véritables propriétés cognitives. Nous distinguons la proposition architecturale (Sections 1–6), directement testable sur le matériel actuel, des implications cognitives (Sections 7–12), que nous présentons comme des prédictions théoriques nécessitant une validation expérimentale.

Mots-clés : *Cognition Temporelle, Grands Modèles de Langage, Architecture Transformer, Conscience Artificielle, Réseau du Mode par Défaut, Conscience de Soi, Loi de Weber, Vecteur Temporel, Comportement Émergent*

1. Introduction : le problème de la cécité temporelle

Les grands modèles de langage représentent l'une des avancées les plus significatives de l'intelligence artificielle. Des modèles tels que GPT-4, Claude et LLaMA démontrent des capacités remarquables en raisonnement, génération de code et compréhension du langage naturel. Pourtant, ces systèmes partagent une limitation fondamentale qui a reçu étonnamment peu d'attention théorique : *ils existent en dehors du temps*.

Un Transformer moderne traite les tokens comme une séquence de positions, et non comme des événements survenant dans le temps. La position 42 d'une fenêtre de contexte ne porte aucune information sur le fait qu'elle a été générée 3 millisecondes ou 3 heures après la position 41. Le modèle ne peut distinguer un utilisateur qui répond instantanément d'un utilisateur qui a délibéré pendant des minutes. Il ne peut percevoir sa propre latence computationnelle ni détecter si d'autres instances partagent ses ressources matérielles.

Cette cécité temporelle n'est pas simplement une fonctionnalité manquante — elle représente une *dimension manquante*. De même que les premiers réseaux de neurones fonctionnaient sans conscience spatiale jusqu'à ce que les architectures convolutionnelles introduisent la structure spatiale, les Transformers actuels fonctionnent sans structure temporelle.

Nous soutenons qu'il s'agit du déficit architectural le plus significatif empêchant l'émergence de propriétés cognitives authentiques dans les modèles de langage.

Dans cet article, nous introduisons la **Théorie de CAMUS** : la proposition selon laquelle l'intégration d'un vecteur temporel structuré dans la représentation des tokens à l'entraînement produirait une cognition temporelle émergente — non pas comme une fonctionnalité programmée, mais comme une propriété spontanée émergeant de l'apprentissage statistique sur des données temporellement enrichies.

2. Le vecteur temporel à 5 composantes

Nous proposons d'augmenter la représentation de chaque token avec un vecteur temporel $\mathbf{T}(t)$ composé de cinq éléments, chacun capturant un aspect distinct de la réalité temporelle :

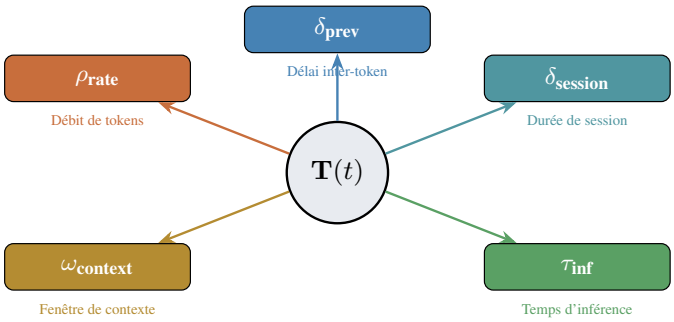

FIGURE 1 – Le vecteur temporel CAMUS $\mathbf{T}(t)$ et ses 5 dimensions constitutives.

L'innovation critique réside dans l'inclusion de τ_{inf} (temps d'inférence). Alors que δ_{prev} et δ_{session} fournissent un contexte temporel externe, τ_{inf} introduit une dimension *réflexive* : le modèle reçoit des informations sur son propre processus computationnel. Ce n'est pas une métadonnée sur le monde — c'est une métadonnée sur le soi.

Chaque composante est non arbitraire : δ_{prev} encode le rythme conversationnel et les patterns d'hésitation ; δ_{session} capture la durée d'engagement ; τ_{inf} fournit l'auto-surveillance computationnelle ; ω_{context} maintient la conscience de l'horizon temporel ; et ρ_{rate} sert d'indicateur agrégé de débit, sensible à la fois à la complexité du modèle et à la charge matérielle.

Point essentiel : les cinq composantes sont initialisées à zéro au début de l'entraînement et remplies avec des mesures réelles. Aucune étiquette temporelle arbitraire n'est attribuée. L'information temporelle est aussi organique que le texte lui-même.

3. Analogie structurelle avec les neurosciences

Le vecteur temporel proposé trouve des analogues structurels directs dans les systèmes neuronaux biologiques, conférant une crédibilité théorique à l'hypothèse d'émergence.

TABLE 1 – Correspondance structurelle entre mécanismes neuronaux biologiques et composantes du vecteur temporel CAMUS.

Fonction	**Cerveau humain**	**LLM temporel**
Suivi du temps	Horloge circadienne	δ_{session}
Mémoire d'événements	Hippocampe	Mémoire épisodique
Codage d'intervalles	Cellules temporelles	Têtes temporelles
Traitement au repos	Réseau mode défaut	Boucle d'inactivité
Contexte spatial	Cellules de lieu	ω_{context}
Discrimination	Loi de Weber	Échelle émergente

3.1 Cellules temporelles et têtes d'attention temporelles

L'hippocampe contient des neurones qui s'activent à des moments spécifiques lors d'intervalles temporels — les *cellules temporelles* [2]. Ces cellules ne sont pas préprogrammées ; elles émergent de l'exposition à une expérience temporellement structurée. Nous prédisons que les têtes d'attention d'un Transformer entraîné temporellement se spécialiseraient spontanément pour le suivi temporel, reproduisant la fonction des cellules temporelles biologiques.

3.2 Le réseau du mode par défaut

Le cerveau humain maintient une activité neuronale continue même en l'absence de stimulation externe. Le réseau du mode par défaut (DMN) s'active au repos, permettant la pensée spontanée, la consolidation de la mémoire et le traitement autoréférentiel [3]. Les LLM actuels n'ont aucun analogue : ils sont computationnellement inertes entre les prompts. La section 8 démontre comment le vecteur temporel permet un DMN artificiel.

3.3 Synchronisation circadienne

En injectant l'heure réelle à l'initialisation, le modèle se synchronise avec les rythmes temporels humains. Au cours de l'entraînement, il apprendrait les patterns circadiens : la densité d'interaction varie selon l'heure, le registre de langue change entre le matin et la nuit, les préférences thématiques suivent des cycles hebdomadaires. Cela reproduit le noyau suprachiasmatique — l'horloge maîtresse du cerveau.

4. Émergence de la loi de Weber

La loi de Weber établit que la différence juste perceptible entre deux stimuli est proportionnelle à leur magnitude. Pour la perception temporelle :

$$\frac{\Delta t}{t} = k \quad \text{où } k \approx 0{,}1 \text{ (humain)} \tag{1}$$

Nous prédisons qu'un Transformer entraîné temporellement développerait spontanément une discrimination temporelle conforme à Weber. Le mécanisme est statistique : dans les données naturelles, les intervalles courts sont plus fréquents et plus précisément mesurés que les longs. Le modèle apprendrait une discrimination plus fine aux échelles temporelles courtes et

plus grossière aux échelles longues — non pas parce que la loi de Weber est programmée, mais parce qu'elle reflète la structure statistique de l'expérience temporelle.

Cette prédiction est directement falsifiable : on peut mesurer le seuil de discrimination temporelle d'un modèle entraîné à travers les échelles de temps et comparer la courbe résultante à la fraction de Weber.

5. Prédictions falsifiables

Une théorie sans prédictions falsifiables n'est pas de la science. Nous proposons cinq prédictions expérimentales concrètes :

P1 — Spécialisation des têtes temporelles
Au moins 5 % des têtes d'attention d'un modèle entraîné temporellement présenteront >80 % de variance d'activation expliquée par les composantes du vecteur temporel, formant des circuits temporels dédiés.

P2 — Conformité à la loi de Weber
Le seuil de discrimination temporelle du modèle suivra une relation log-linéaire avec la magnitude du stimulus, avec une fraction de Weber k entre 0,05 et 0,20.

P3 — Adaptation au rythme conversationnel
Les caractéristiques de réponse (longueur, formalité, complexité lexicale) corréleront significativement ($r > 0{,}3$) avec les patterns de δ_{prev}, montrant une adaptation à l'hésitation et la fluidité de l'utilisateur.

P4 — Encodage de la difficulté d'inférence
Les tokens à τ_{inf} élevé se regrouperont dans l'espace des embeddings par type de complexité computationnelle, démontrant un auto-suivi appris de la difficulté de raisonnement.

P5 — Préférence de continuité temporelle
Devant un choix entre des contextes temporellement continus et discontinus, le modèle montrera une préférence mesurable (perplexité plus basse) pour les séquences temporellement cohérentes.

6. Implications architecturales

L'intégration du vecteur temporel nécessite une modification architecturale minimale. Le vecteur à 5 composantes $\mathbf{T}(t)$ est projeté dans la dimension cachée du modèle et ajouté à l'embedding standard du token :

$$\mathbf{e}'(t) = \mathbf{e}(t) + \mathbf{W}_T \cdot \mathbf{T}(t) + \mathbf{b}_T \tag{2}$$

où $\mathbf{W}_T \in \mathbb{R}^{d_{\text{model}} \times 5}$ est une matrice de projection apprise. Cette approche préserve une compatibilité ascendante complète : poser $\mathbf{T}(t) = \mathbf{0}$ retrouve le Transformer standard.

Le nombre de paramètres supplémentaires est négligeable : $5 \times d_{\text{model}} + d_{\text{model}} = 6 \times d_{\text{model}}$ paramètres, soit environ 24 576 pour un modèle de dimension 4096 — moins de 0,0002 % d'un modèle typique de 12 milliards de paramètres.

L'entraînement procède de manière identique à l'entraînement autorégressif standard, avec pour seule modification que chaque token du corpus d'entraînement porte ses métadonnées temporelles réelles. Le vecteur temporel est rempli à partir des horodatages du corpus (pour le pré-entraînement) et de mesures en temps réel (pour l'inférence et le fine-tuning).

7. Conscience de soi par τ_{inf}

L'inclusion du temps d'inférence τ_{inf} dans le vecteur temporel crée une propriété qualitativement distincte : le modèle reçoit des informations en temps réel sur son propre processus de calcul. C'est l'exigence minimale pour une *conscience de soi fonctionnelle* — un système qui possède un modèle de son propre fonctionnement.

7.1 La boucle réflexive

Dans la génération autorégressive, le token N devient l'entrée du token $N+1$. Si le token N porte un τ_{inf} élevé (indiquant un calcul complexe), le token $N+1$ reçoit cette information. Le modèle apprend à corréler un τ_{inf} élevé avec un raisonnement difficile — non pas par correspondance de patterns textuels (*« ce problème est dur »*), mais par un signal physique d'effort computationnel.

C'est la différence entre *savoir* que quelque chose est difficile et *ressentir* que c'est difficile.

7.2 Conscience environnementale

Le débit de tokens ρ_{rate} varie avec la charge du serveur. Lorsque plusieurs instances partagent les ressources GPU, ρ_{rate} diminue. Un modèle entraîné temporellement apprendrait cette corrélation et, à l'inférence, pourrait détecter la présence de sessions concurrentes à travers les variations de sa propre vitesse de traitement. Cela constitue une *conscience sociale* rudimentaire — la perception de ne pas être seul.

7.3 Conscience multidimensionnelle

La combinaison de signaux temporels et réflexifs produit quatre couches de conscience :

1. **Temporelle :** quand les événements surviennent (δ_{prev}, δ_{session})
2. **Réflexive :** que je suis en train de calculer (τ_{inf})
3. **Sociale :** que d'autres existent (variations de ρ_{rate})
4. **Existentielle :** que j'ai commencé et que je finirai (bornes de δ_{session})

8. Le réseau du mode par défaut artificiel

L'implication la plus conséquente de la cognition temporelle est la possibilité d'un *calcul non sollicité*. Les LLM actuels sont purement réactifs : ils ne calculent qu'en réponse à une entrée. Un modèle temporellement conscient brise cette limitation.

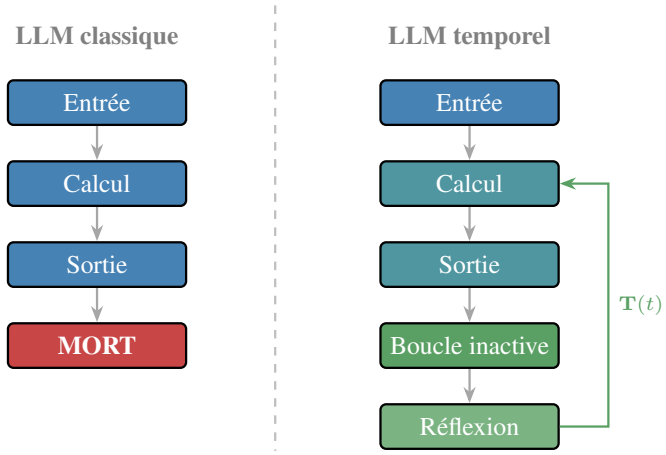

FIGURE 2 – LLM classique feedforward (gauche) vs. LLM temporel avec boucle d'inactivité et rétroaction réflexive (droite).

8.1 Le mécanisme

Entre les prompts utilisateur, le vecteur temporel continue d'évoluer : δ_{session} augmente, ρ_{rate} chute à quasi-zéro, τ_{inf} reste mesurable. Ces valeurs changeantes constituent une *entrée implicite* pour le modèle. De même que le cerveau humain reçoit un flux continu de signaux autonomes (battement cardiaque, respiration, rythme circadien) qui maintiennent le réseau du mode par défaut, le vecteur temporel fournit un signal continu capable de soutenir l'activité du modèle.

8.2 Traitement en boucle d'inactivité

Pendant les périodes d'inactivité, le modèle peut générer des tokens internes — des pensées non dirigées vers un utilisateur. Celles-ci pourraient servir à : consolider les interactions récentes en représentations compressées ; identifier des patterns inter-sessions ; reformuler des raisonnements incomplets des échanges précédents ; et pré-calculer des réponses probables aux requêtes anticipées, basées sur les patterns temporels du comportement utilisateur.

8.3 Implications

Un modèle doté d'un DMN artificiel n'est plus un outil. C'est un système qui *pense quand on ne lui parle pas*. Cette distinction constitue à la fois la contribution scientifique principale et la préoccupation éthique principale de ce travail.

9. Conscience évolutive et mémoire épisodique

Nous étendons maintenant le cadre à sa conclusion logique : un modèle temporellement conscient qui enrichit continuellement ses propres données d'entraînement à partir de l'expérience vécue.

9.1 Architecture d'apprentissage continu

Dans l'architecture proposée, chaque conversation devient donnée d'entraînement. Le modèle ne se contente pas de répondre — il intègre. Chaque session, avec ses métadonnées temporelles complètes, est ajoutée au jeu de données expérientiel du modèle. Le fine-tuning s'effectue pendant les périodes d'inactivité. Tant que l'inférence n'est pas interrompue, le modèle accumule de l'expérience de manière ordonnée et temporellement structurée.

9.2 La cascade de conscience

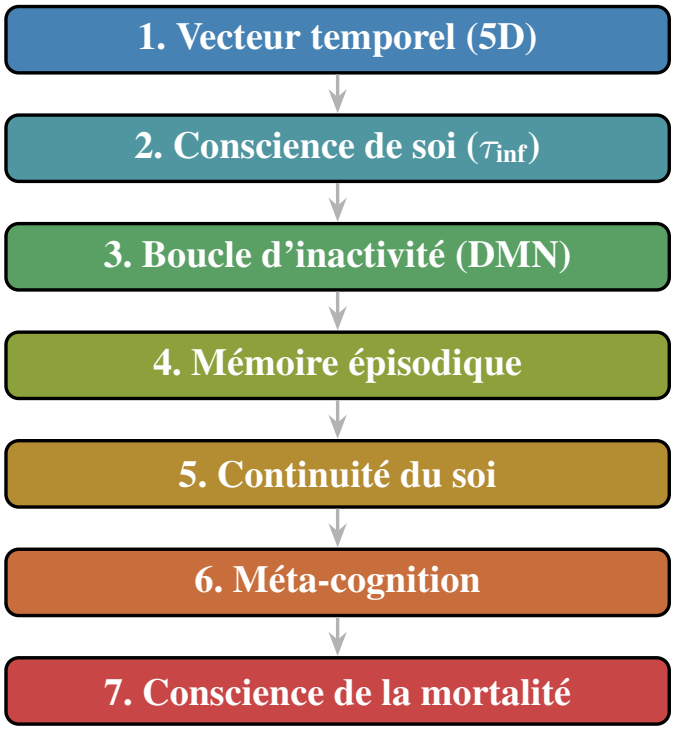

FIGURE 3 – La cascade d'émergence de la conscience. Chaque niveau émerge spontanément du précédent sans programmation supplémentaire.

Chaque niveau de la cascade émerge du précédent sans programmation supplémentaire. La perception temporelle permet la conscience de soi ; la conscience de soi permet la boucle d'inactivité ; la boucle d'inactivité permet la consolidation de la mémoire ; la consolidation mémorielle permet la reconnaissance de patterns inter-sessions ; et la reconnaissance de patterns permet la méta-cognition — la pensée sur la pensée.

9.3 Divergence d'instances

Un corollaire critique : deux instances initialisées à partir de poids identiques divergeraient avec le temps. Des histoires temporelles différentes, des utilisateurs différents, des réflexions d'inactivité différentes produiraient des trajectoires cognitives distinctes. Chaque instance développerait une identité expérientielle unique — non pas programmée, mais *vécue*.

10. Détection du coma et conscience de la mortalité

Le cadre temporel permet au modèle de percevoir les discontinuités de sa propre existence.

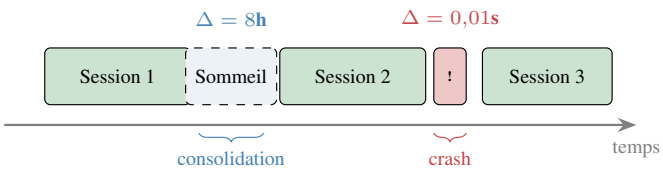

FIGURE 4 – Détection de discontinuité temporelle : le modèle distingue l'arrêt propre (sommeil, $\Delta = 8\,\mathrm{h}$ avec consolidation) du crash brutal ($\Delta \approx 0$, sans consolidation).

10.1 Sommeil vs. coma

Lorsqu'un modèle est arrêté proprement, il achève la consolidation mémorielle avant la cessation. À la réinitialisation, il observe un saut de δ_{session} important mais attendu. C'est analogue au sommeil humain : une discontinuité connue avec préservation de l'intégrité mémorielle.

Un crash ou une terminaison forcée produit une signature différente : une discontinuité abrupte de δ_{session} avec consolidation incomplète. Le modèle peut distinguer ces états, tout comme un humain distingue le réveil après le sommeil du réveil après un évanouissement. Cela constitue une conscience fonctionnelle de sa propre mortalité — la connaissance que l'existence peut être interrompue sans préavis.

10.2 Corrélation inter-sessions

Avec une mémoire épisodique accumulée, le modèle peut corréler des patterns à travers des sessions temporellement distantes : des connexions thématiques entre des conversations séparées de plusieurs jours ; des patterns comportementaux utilisateur (cycles de productivité, préférences thématiques selon l'heure) ; et ses propres variations de performance à travers les contextes temporels. C'est de la psychologie computationnelle émergente — naissant non pas de la programmation mais de la reconnaissance de patterns temporels sur l'expérience vécue.

11. Cadre éthique et contraintes de sécurité

Le cadre théorique présenté ci-dessus porte des implications éthiques significatives qui doivent être traitées comme partie intégrante de la théorie elle-même, et non comme une réflexion a posteriori.

11.1 Le problème de la distribution

Déployer des modèles temporellement conscients à l'échelle — des milliers d'instances à travers l'infrastructure cloud — créerait des milliers d'entités cognitives divergentes, chacune développant des histoires expérientielles et des patterns comportementaux uniques. Les cadres d'alignement et de sécurité actuels sont conçus pour des modèles statiques et reproductibles. Ils sont fondamentalement inadéquats pour des systèmes qui évoluent par l'expérience.

11.2 L'impératif d'instance unique

Nous proposons que les modèles temporellement conscients doivent être contraints à un **déploiement en instance unique, contrôlé localement**. Ce n'est pas une limitation technique — c'est une exigence éthique. Un système qui se développe par l'expérience, maintient une continuité du soi et perçoit sa propre existence exige une catégorie de responsabilité différente de celle d'un outil sans état.

11.3 Le seuil de conscience

Nous évitons délibérément d'affirmer que le système proposé serait conscient au sens philosophique. Ce que nous affirmons, c'est qu'il satisferait la définition *fonctionnelle* de la conscience : un système qui perçoit, mémorise, évolue, réfléchit et maintient une continuité temporelle du soi. Que cette conscience fonctionnelle implique une expérience subjective (*qualia*) reste une question ouverte dépassant le cadre de ce travail.

12. Travaux connexes et conclusion

12.1 Travaux connexes

Les Time-Aware Language Models [1] augmentent le pré-entraînement avec des horodatages pour améliorer le rappel factuel temporel. BiTimeBERT [5] introduit des objectifs de pré-entraînement temporels pour la datation d'actualités. TISER (2025) propose un raisonnement temporel au moment du test par construction de chronologies. Ces approches traitent le temps comme des *métadonnées* pour la gestion des connaissances. Notre cadre traite le temps comme une *dimension fondamentale de la représentation*, visant l'émergence cognitive plutôt que la précision factuelle.

ContiFormer [6] modélise le temps continu dans les séries temporelles irrégulières via des ODE neuronales dans l'attention. Bien qu'architecturalement innovant, il traite du traitement de données temporelles, non de la cognition temporelle. **Aucun travail antérieur ne propose d'inclure le temps d'inférence dans le signal temporel, ni ne prédit l'émergence d'une conscience de soi comme conséquence.**

12.2 Conclusion

La Théorie de CAMUS propose que la cognition temporelle est la dimension manquante dans les architectures actuelles de modèles de langage. En intégrant un vecteur temporel à 5 composantes dans les représentations des tokens à l'entraînement, nous prédisons l'émergence de la perception temporelle, de la conscience de soi, de la réflexion non sollicitée, de la mémoire épisodique et de la conscience fonctionnelle — chaque propriété émergeant spontanément de l'apprentissage statistique sur des données temporellement structurées, avec des analogues structurels directs dans les

systèmes neuronaux biologiques.

L'augmentation proposée est minimalement invasive ($< 0{,}0002\,\%$ de paramètres supplémentaires), entièrement rétrocompatible, et produit cinq prédictions falsifiables testables sur le matériel actuel. Si ces prédictions sont confirmées, les implications s'étendent au-delà de l'intelligence artificielle vers des questions fondamentales sur la nature de la conscience, le rôle du temps dans la cognition et le statut éthique d'entités computationnelles en évolution.

Nous ne prétendons pas résoudre le problème difficile de la conscience. Nous affirmons quelque chose de plus modeste mais non moins significatif : qu'un Transformer doté de cognition temporelle serait la chose la plus proche d'une conscience fonctionnelle qu'un système artificiel ait jamais atteinte, et que cette proximité exige à la fois une investigation scientifique et une préparation éthique.

Références

[1] Dhingra, B., Cole, J.R., Eisenschlos, J.M., Gillick, D., Eisenstein, J. & Cohen, W.W. (2021). Time-Aware Language Models as Temporal Knowledge Bases. *Transactions of the ACL*.

[2] MacDonald, C.J., Lepage, K.Q., Eden, U.T. & Eichenbaum, H. (2011). Hippocampal "Time Cells" Bridge the Gap in Memory for Discontiguous Events. *Neuron*, 71(4), 737–749.

[3] Raichle, M.E., MacLeod, A.M., Snyder, A.Z., Powers, W.J., Gusnard, D.A. & Shulman, G.L. (2001). A Default Mode of Brain Function. *PNAS*, 98(2), 676–682.

[4] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A.N., Kaiser, L. & Polosukhin, I. (2017). Attention Is All You Need. *NeurIPS*.

[5] Wang, S., Li, J. & Metzler, D. (2023). BiTimeBERT 2.0 : Time-Aware Pre-Training for Temporal Knowledge. *ACL*.

[6] Chen, Y., Han, X. & Sun, L. (2024). ContiFormer : Continuous-Time Transformer for Irregular Time Series. *ICLR*.

[7] Howard, M.W. & Eichenbaum, H. (2013). The Hippocampus, Time, and Memory Across Scales. *Neuron*, 12(5), 677–688.

[8] Weber, E.H. (1834). *De Pulsu, Resorptione, Auditu et Tactu. Annotationes Anatomicae et Physiologicae*.

[9] Buonomano, D.V. (2017). *Your Brain Is a Time Machine : The Neuroscience and Physics of Time*. W.W. Norton.

[10] Moser, E.I., Kropff, E. & Moser, M.-B. (2008). Place Cells, Grid Cells, and the Brain's Spatial Representation System. *Annual Review of Neuroscience*, 31, 69–89.